GLOBAL SOLUTION 2026.2 — MLAM

Relatório Estatístico

Saneamento básico nos municípios brasileiros: urbanização, educação e renda (Censo 2022)

Desafio CitizenTech — cidades, campo e comunidades

Integrante	RM
Gabriel Villas	RM 571603
Nathan Werner	RM 572925

Fonte dos dados: IBGE — Censo Demográfico 2022 e PIB dos Municípios 2021 (API SIDRA)

1. Sumário executivo

Este relatório analisa os **5.538 municípios brasileiros** com dados completos no Censo 2022 para responder a uma pergunta de política pública: **o que explica a desigualdade no acesso ao saneamento básico entre os municípios, e como identificar os municípios com maior risco de esgoto inadequado?**

Principais achados

- O esgoto é o serviço menos universalizado: em média, só **37,9%** dos domicílios de cada município estão ligados à rede, contra cerca de 72% para água encanada e 80% para coleta de lixo. Em **33,5%** dos municípios, menos de 10% dos domicílios estão ligados à rede de esgoto.
- A desigualdade regional é forte: a cobertura média de esgoto vai de **7,5%** no Norte a **70,6%** no Sudeste. No Sudeste, 80,9% dos municípios têm esgoto adequado (≥ 50% dos domicílios ligados); no Norte, só 2,3%.
- A urbanização tem **correlação forte** com a coleta de lixo (r = 0,740) e explica **54,7%** da sua variação.
- Urbanização, alfabetização e densidade explicam juntas **42,0%** da variação da cobertura de esgoto, com efeitos positivos e significativos.
- A regressão logística classifica corretamente **77,1%** dos municípios de teste (contra 62,1% do modelo ingênuo) e identifica **83,4%** dos municípios com esgoto inadequado. Um **PIB per capita alto não aumenta, por si só, a chance de ter esgoto adequado**.

Recomendação central: priorizar investimentos e soluções descentralizadas de esgotamento (fossas sépticas adequadas, sistemas condominiais) em **municípios pequenos, rurais, pouco densos e com baixa alfabetização**, sobretudo no Norte e no Nordeste. O modelo logístico pode servir como **ferramenta de triagem** desses municípios.

2. Contextualização do problema

O saneamento básico (abastecimento de água, esgotamento sanitário e manejo de resíduos sólidos) é um direito previsto na Lei 11.445/2007, e o Novo Marco Legal do Saneamento (Lei 14.026/2020) estabeleceu a meta de 99% da população com água potável e 90% com coleta e tratamento de esgoto até 2033. A falta de saneamento está ligada a doenças de veiculação hídrica, à poluição de rios e à perda de qualidade de vida, e atinge mais as comunidades rurais e periféricas.

No contexto do desafio **CitizenTech**, que busca soluções tecnológicas para cidades, campo e comunidades, entender **quais características dos municípios estão associadas ao déficit de saneamento** ajuda a direcionar recursos, escolher tecnologias adequadas a cada território e acompanhar o progresso rumo às metas de 2033.

Objetivos das análises: (i) descrever a cobertura de água, esgoto e lixo nos municípios; (ii) aplicar modelos de probabilidade e testes de hipóteses a indicadores de saneamento e educação; (iii) medir a relação entre urbanização e coleta de lixo; (iv) modelar a cobertura de esgoto a partir de fatores estruturais; e (v) classificar os municípios quanto ao risco de esgoto inadequado.

3. Dados e procedimentos

Todos os dados são **reais e oficiais**, obtidos pela API pública do Sistema IBGE de Recuperação Automática (SIDRA, https://apisidra.ibge.gov.br). A coleta é automatizada (*src/01_coleta_dados.py*) e cada tabela é salva sem alterações em *data/raw/*.

Tabela SIDRA	Conteúdo	Variável derivada
4714 (Censo 2022)	População, área e densidade	populacao, densidade_hab_km2, log_densidade
9923 (Censo 2022)	População por situação do domicílio	pct_pop_urbana
6805 (Censo 2022)	Domicílios por tipo de esgotamento	pct_esgoto_rede, esgoto_adequado
6803 (Censo 2022)	Domicílios por forma de abastecimento de água	pct_agua_rede
6892 (Censo 2022)	Domicílios por destino do lixo	pct_lixo_coletado
9543 (Censo 2022)	Taxa de alfabetização (15 anos ou mais)	taxa_alfabetizacao
5938 (PIB Mun. 2021)	PIB, VAB total e VAB agropecuário	pib_per_capita, log_pib_per_capita, pct_vab_agro

Tratamento (*src/02_tratamento_dados.py*): as tabelas foram unidas pelo código IBGE do município. Os símbolos do SIDRA para valor inexistente ('-', '...', 'X') foram convertidos em ausentes, e os registros incompletos foram removidos (5.570 → 5.538 municípios). Foram criadas as variáveis PIB per capita (PIB 2021 ÷ população 2022), participação da agropecuária no VAB, logaritmos da densidade e do PIB per capita (para reduzir a assimetria) e a variável binária **esgoto_adequado** = 1 quando ≥ 50% dos domicílios estão ligados à rede de esgoto.

Ferramentas: Python 3.12 com pandas, NumPy, SciPy, statsmodels, scikit-learn, matplotlib e seaborn. Todas as análises estão no notebook *notebooks/analise_estatistica.ipynb*, com as saídas preservadas. Sementes aleatórias fixas garantem a reprodutibilidade das amostras e da divisão treino/teste.

4. Análise descritiva

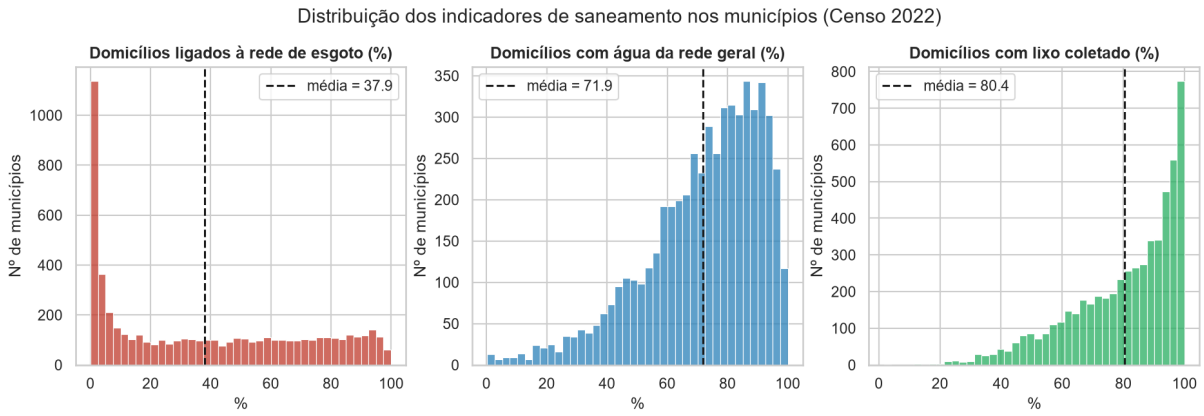


Figura 1 — Distribuição dos indicadores de saneamento entre os municípios (Censo 2022).

A coleta de lixo e a água encanada têm distribuições concentradas em valores altos, ou seja, estão perto da universalização na maioria dos municípios. O esgoto é o oposto: a distribuição é muito dispersa, com média de 37,9% e mediana de 32,6%, e há um grande pico perto de zero. Um terço dos municípios praticamente não tem rede de esgoto.

Região	Municípios	Esgoto rede (%)	Água rede (%)	Lixo coletado (%)	Pop. urbana (%)	Alfabetização (%)	Mun. com esgoto adequado (%)
Norte	442	7,5	53,5	66,4	63,0	87,7	2,3
Centro-Oeste	466	20,8	73,6	81,7	76,3	91,2	16,3
Nordeste	1776	24,7	67,7	71,0	61,1	79,6	18,4
Sul	1186	29,9	74,3	86,9	67,0	94,4	28,5
Sudeste	1668	70,6	79,1	89,1	78,9	92,4	80,9

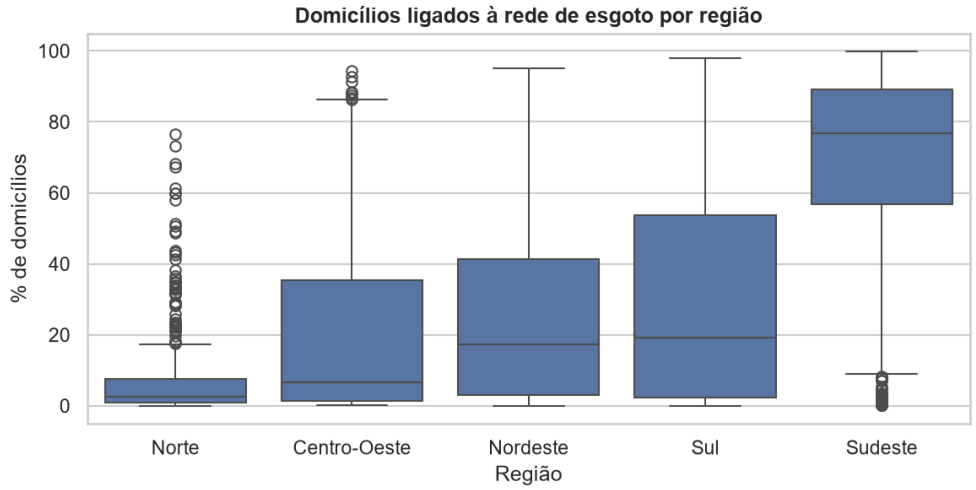


Figura 2 — Domicílios ligados à rede de esgoto por grande região.

A desigualdade regional é a característica mais marcante. O Norte tem a pior cobertura em todos os serviços. O Nordeste tem a menor alfabetização e baixa urbanização. O Sul, embora rico e alfabetizado, tem cobertura de esgoto em rede relativamente baixa, porque historicamente usa muitas fossas sépticas. O Sudeste concentra os municípios com esgoto adequado.

5. Distribuição Normal de Probabilidade

Variável: **taxa de alfabetização (15 anos ou mais)**, assumida como X ~ N(μ = 88,23; σ = 7,54). A mediana observada é 90,66%.

Evento	Cálculo	Probabilidade	Classificação
a) X < média	P(Z < 0)	0,5000 (50,00%)	Evento equiprovável (50%)
b) X > mediana	P(Z > (90,66 − 88,23) / 7,54)	0,3741 (37,41%)	Evento improvável (pouco provável)

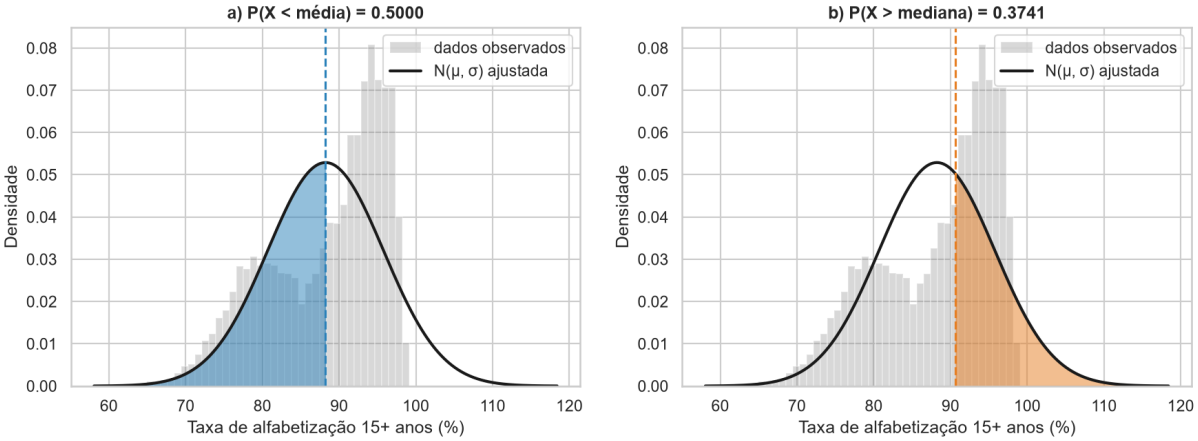


Figura 3 — Curva normal ajustada à taxa de alfabetização e áreas das probabilidades calculadas.

Interpretação. (a) A média é o centro de simetria da normal, então a probabilidade de um município ter alfabetização abaixo da média é exatamente 50%: um **evento equiprovável**. (b) Como a mediana (90,7%) é maior que a média (88,2%), a probabilidade de superar a mediana no modelo normal é de 37,4%, um **evento improvável (pouco provável)**. Nos dados reais essa proporção é 50% por definição. A diferença mostra que a distribuição observada é **assimétrica à esquerda**: um grupo de municípios, concentrado no Nordeste, tem alfabetização muito abaixo do restante e puxa a média para baixo. A Figura 3 deixa isso claro, com dois 'picos' no histograma. A normal é útil como aproximação, mas subestima a concentração de municípios com alfabetização alta.

6. Testes de hipóteses para a média

Variável: **% de domicílios com água da rede geral**. Média populacional de referência μ_0 = 71,90% e desvio padrão populacional σ = 19,34 p.p. (calculados sobre todos os municípios). Como σ é conhecido, aplicou-se o teste Z, $Z = (\bar{x} - \mu_0) / (\sigma/\sqrt{n})$, em amostras aleatórias simples sorteadas com semente fixa.

	Hipóteses	α	n	$\bar{x}$	Z calc.	Z crítico	p-valor	Decisão
a)	H0: μ = μ0 × H1: μ < μ0	6%	20	78,55	1,538	-1,555	0,9380	Não rejeita H0
b)	H0: μ = μ0 × H1: μ > μ0	9%	25	79,34	1,923	1,341	0,0272	Rejeita H0

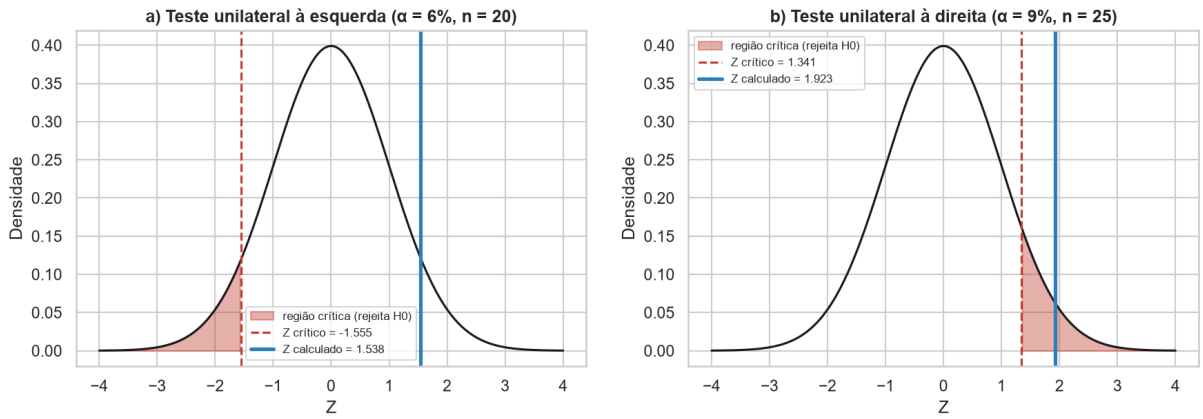


Figura 4 — Estatística Z calculada e regiões críticas dos testes unilaterais.

Interpretação. (a) A amostra de 20 municípios teve média de 78,6%, **acima** da referência. Por isso a estatística Z ficou positiva, longe da região crítica à esquerda, e **não há evidência** de que a cobertura de água seja menor que a média nacional. (b) A amostra de 25 municípios teve média de 79,3%, com Z = 1,92 acima do valor crítico (1,341) e p-valor de 0,027 < 0,09, o que leva a **rejeitar H0** e a concluir, ao nível de 9%, que a média é maior que a referência.

Leitura crítica: como μ_0 é a própria média de todos os municípios, a rejeição em (b) é um exemplo de **erro tipo I**, cuja probabilidade é α = 9%. Para quem toma decisões, a lição é que conclusões tiradas de amostras pequenas dependem da amostra sorteada e do nível de significância. Com uma base censitária completa disponível, ela deve ser preferida.

7. Análise bivariada: urbanização × coleta de lixo

X = população urbana (%) e Y = domicílios com lixo coletado (%).

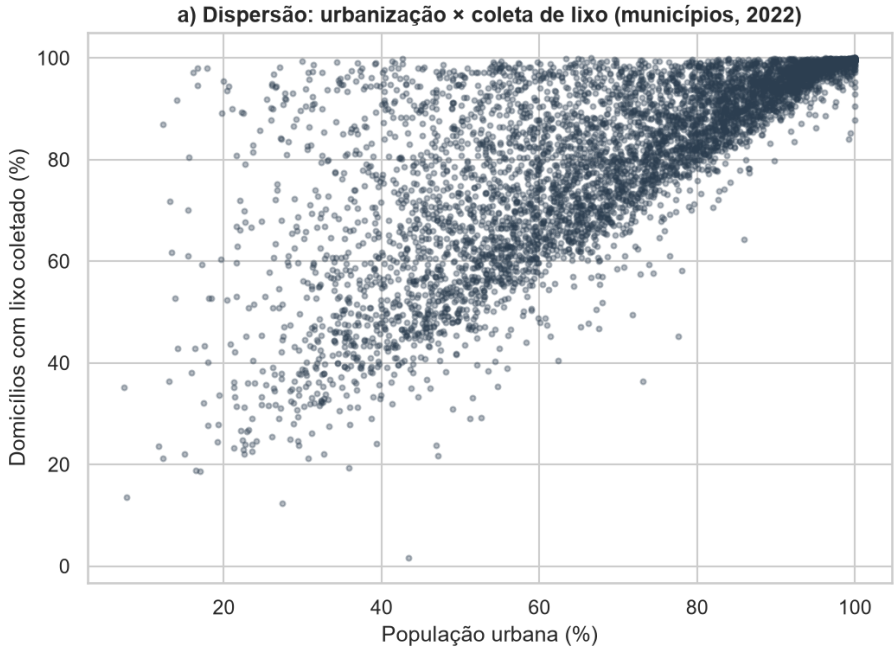


Figura 5 — Gráfico de dispersão entre urbanização e coleta de lixo.

(a) Dispersão. A nuvem de pontos é ascendente, o que indica **associação positiva**. A variabilidade da coleta é grande entre os municípios pouco urbanizados e diminui perto de 100% de urbanização, onde a coleta tende a ser universal. Esse padrão de variância desigual é chamado de heterocedasticidade.

Medida	Valor	Interpretação
Covariância amostral	257,25	Positiva: as variáveis crescem juntas (valor em %², não mede a força da relação)
Correlação de Pearson (r)	0,7396	Correlação linear positiva forte (r > 0,7)
p-valor de r	< 0,0001	Correlação estatisticamente significativa

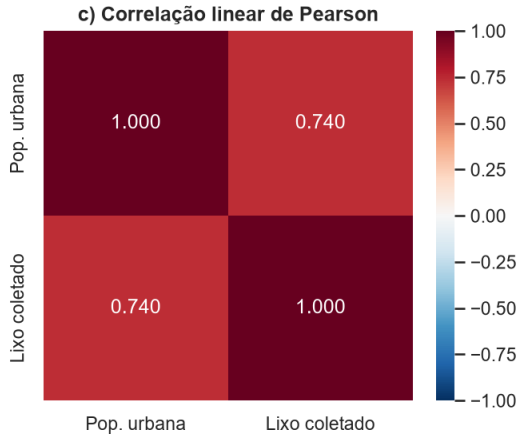


Figura 6 — Gráfico (mapa de calor) da correlação linear de Pearson.

(b, c) Correlação. A covariância só indica a direção da relação. O coeficiente de Pearson, que é padronizado, mostra que a relação é **positiva e forte** (r = 0,740), como se vê na cor intensa do mapa de calor.

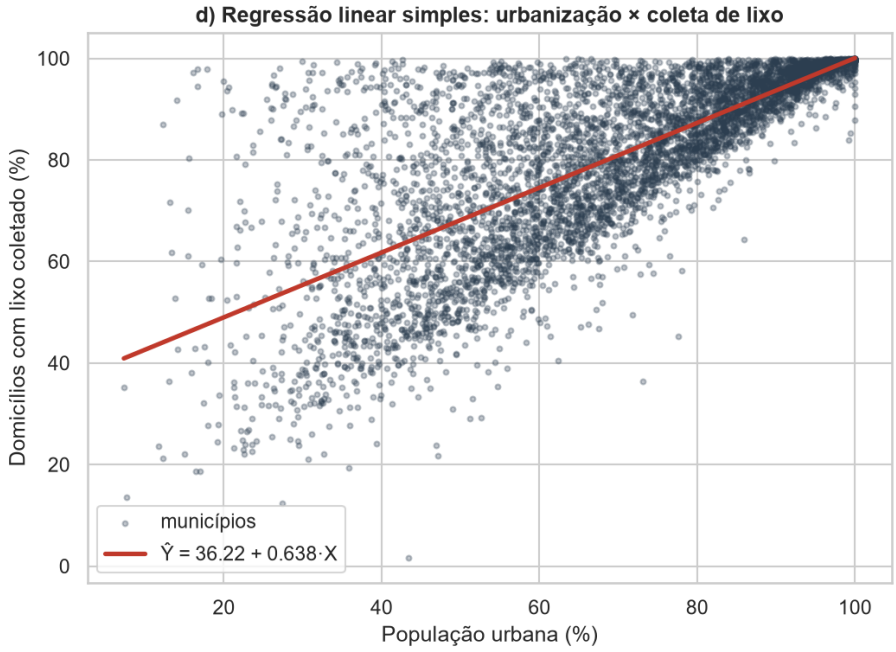


Figura 7 — Reta de regressão linear simples sobre o gráfico de dispersão.

(d) Equação:

$$\hat{Y} = 36{,}2236 + 0{,}6383 \cdot X$$

Cada ponto percentual a mais de população urbana aumenta a coleta de lixo esperada em **0,64 p.p.** Um município hipotético totalmente rural teria 36,2% de coleta.

(e) Adequação do modelo. $R^2 = 0{,}5470$: a urbanização explica **54,7%** da variação da coleta de lixo entre os municípios. O teste F ($F = 6.684{,}7$; p-valor < 0,0001) rejeita H0: $\beta_1 = 0$, então o modelo é **significativo**. Os outros 45% da variação dependem de fatores fora do modelo, como renda, gestão municipal e relevo.

Pop. urbana (%)	Coleta de lixo prevista (%)
40	61,8
60	74,5
90	93,7

(f) Previsão. Um município 40% urbano teria cerca de 62% dos domicílios com coleta e um 90% urbano chegaria a cerca de 94%. As previsões são médias condicionais e só devem ser feitas dentro da faixa observada de X.

8. Regressão linear múltipla: o que explica a cobertura de esgoto

Y = % de domicílios ligados à rede de esgoto; X_1 = população urbana (%); X_2 = taxa de alfabetização (%); X_3 = $\log_{10}$(densidade demográfica).

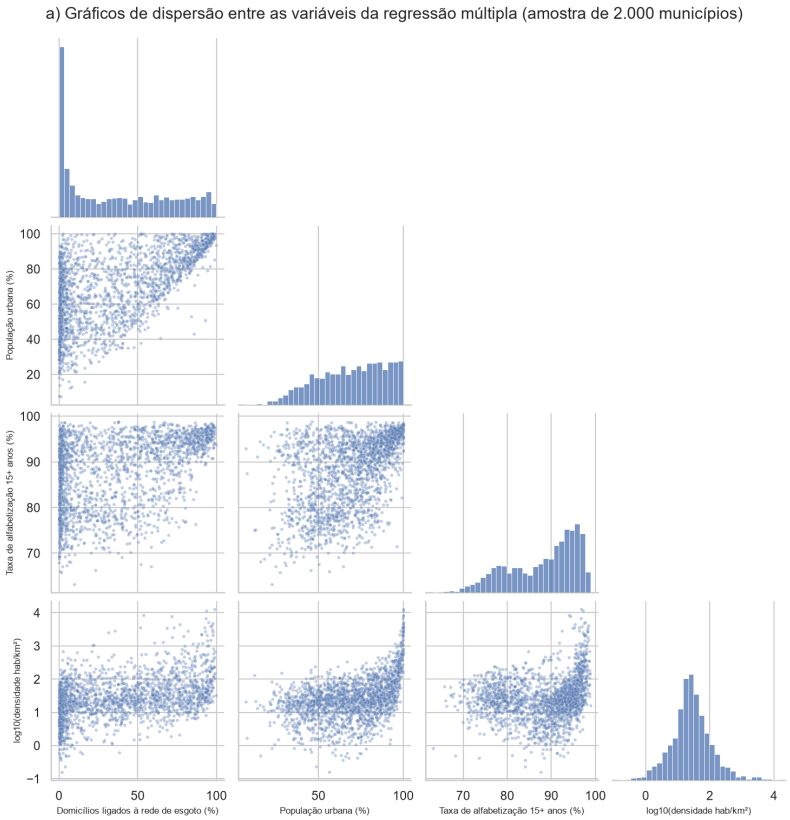


Figura 8 — Matriz de gráficos de dispersão (amostra aleatória de 2.000 municípios).

(a) Dispersão. A cobertura de esgoto cresce com as três variáveis explicativas, de forma mais nítida com a urbanização e a densidade. Há muitos municípios com cobertura próxima de 0% em todas as faixas, até entre os urbanizados, o que mostra que a rede de esgoto também depende de decisões de investimento.

Correlação	Esgoto rede	Pop. urbana	Alfabetização	log Densidade
Esgoto rede	1,000	0,604	0,410	0,428
Pop. urbana	0,604	1,000	0,462	0,434
Alfabetização	0,410	0,462	1,000	0,198
log Densidade	0,428	0,434	0,198	1,000

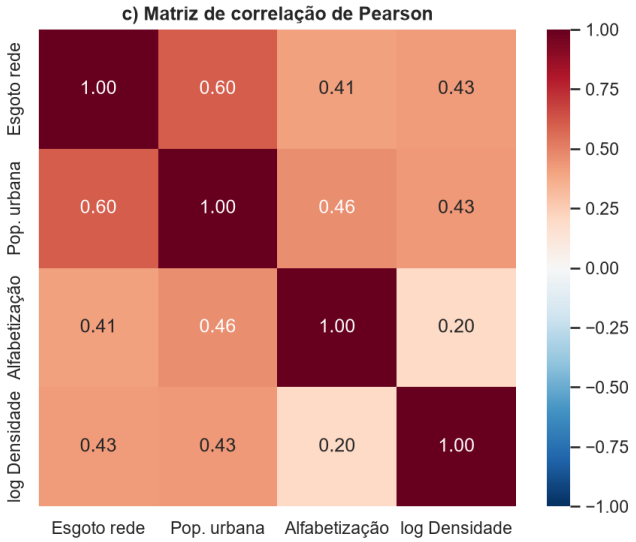


Figura 9 — Matriz de correlação de Pearson.

(b, c) Covariância e correlação. Todas as covariâncias e correlações são positivas. A cobertura de esgoto tem correlação **moderada** com a urbanização (0,60), a densidade (0,43) e a alfabetização (0,41). Entre as explicativas, as correlações são de no máximo 0,46 e os VIF ficam entre 1,2 e 1,5, bem abaixo de 5, o que indica **ausência de multicolinearidade preocupante**. A matriz de covariância completa está no notebook.

(d) Equação da regressão linear múltipla:

$$\hat{Y} = -91{,}3619 + 0{,}7195 \cdot \text{PopUrbana} + 0{,}7297 \cdot \text{Alfabetização} + 10{,}7373 \cdot \log_{10}(\text{Densidade})$$

Variável	Coeficiente	p-valor	Interpretação (mantidas as demais constantes)
Pop. urbana (%)	0,7195	< 0,0001	+1 p.p. urbano → +0,72 p.p. de esgoto
Alfabetização (%)	0,7297	< 0,0001	+1 p.p. alfabetização → +0,73 p.p. de esgoto
log10(Densidade)	10,7373	< 0,0001	densidade 10× maior → +10,7 p.p. de esgoto

(e) Adequação. $R^2 = 0{,}4204$ (R^2 ajustado = 0,4201): o modelo explica **42,0%** da variação da cobertura de esgoto. O teste F (F = 1.338,0; p-valor < 0,0001) rejeita a hipótese de que todos os coeficientes sejam nulos, e cada coeficiente é individualmente significativo. O ajuste é moderado, o que é esperado: a existência de rede depende também do histórico de investimento das companhias estaduais e municipais, de fatores geográficos e de capacidade de gestão, que não estão no modelo.

Perfil	Pop. urbana (%)	Alfabetização (%)	Densidade (hab/km²)	Esgoto previsto (%)
Município A (rural, baixa alfabetização)	50	80	15	15,6
Município B (urbano, alfabetizado, pouco denso)	85	95	15	51,8
Município C (urbano, alfabetizado, denso)	85	95	302	65,7

(f) Previsão. Um município rural, com baixa alfabetização e pouco denso teria cobertura prevista de cerca de 16%, menos da metade da média nacional. Com urbanização e alfabetização altas, a previsão sobe para cerca de 52%, e com densidade de 300 hab/km² chega a cerca de 66%. O efeito da densidade reflete a **economia de escala da rede**: em áreas dispersas, o custo por domicílio ligado é muito maior.

9. Regressão logística binária: classificação do risco de esgoto inadequado

Y = esgoto_adequado (1 se ≥ 50% dos domicílios estão ligados à rede; 0 caso contrário). Explicativas: população urbana, alfabetização, $\log_{10}$(densidade) e $\log_{10}$(PIB per capita). A base foi dividida em 3876 municípios para treino (70%) e 1662 para teste (30%), de forma estratificada.

(a) Equação:

$$\text{logit}(p) = -10{,}2194 + 0{,}0685 \cdot \text{PopUrbana} + 0{,}0975 \cdot \text{Alfabetização} + 0{,}5254 \cdot \log_{10}(\text{Densidade}) - 1{,}0616 \cdot \log_{10}(\text{PIBpc})$$

$$p = 1 / (1 + e^{-\text{logit}(p)})$$

Variável	Coeficiente	Razão de chances	Leitura
Pop. urbana (%)	0,0685	1,071	+1 p.p. → chances +7,1%
Alfabetização (%)	0,0975	1,102	+1 p.p. → chances +10,2%
log10(Densidade)	0,5254	1,691	densidade 10× → chances × 1,69
log10(PIB per capita)	-1,0616	0,346	PIBpc 10× → chances × 0,35

Todos os coeficientes são significativos ($p < 0{,}001$; pseudo-R^2 de McFadden = 0,321). O resultado mais relevante para a política pública é o **sinal negativo do PIB per capita**: com urbanização, alfabetização e densidade fixas, municípios com PIB per capita alto, típicos do agronegócio, da mineração e da geração de energia, têm **menor** chance de esgoto adequado. Riqueza produzida no território não se converte automaticamente em infraestrutura de saneamento.

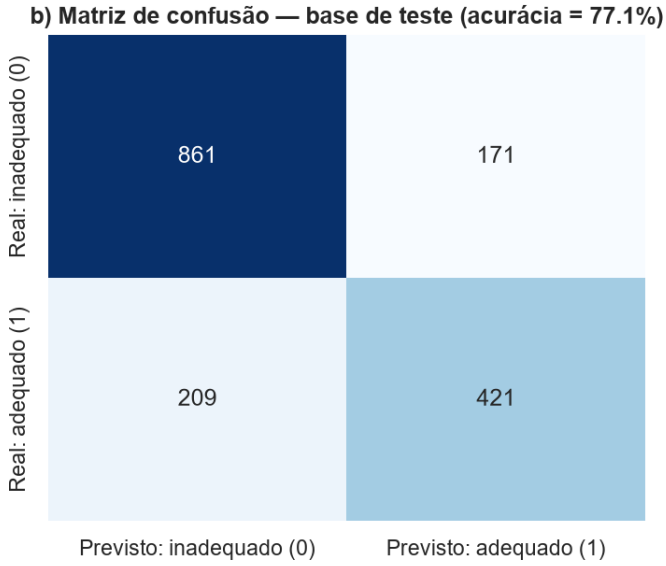


Figura 10 — Matriz de confusão na base de teste (ponto de corte = 0,5).

Métrica	Valor	Significado
Acurácia	77,1%	Proporção total de acertos
Acurácia do modelo ingênuo	62,1%	Prever sempre 'inadequado' (classe majoritária)
Especificidade	83,4%	Acertos entre os municípios com esgoto inadequado
Sensibilidade	66,8%	Acertos entre os municípios com esgoto adequado
Precisão	71,1%	Dos previstos como adequados, quantos realmente são

(b) Interpretação. O modelo acertou 861 municípios com esgoto inadequado e 421 com esgoto adequado, errando 380 de 1662. A acurácia de 77,1% supera em 15,0 p.p. o modelo ingênuo. A

especificidade alta mostra que o modelo é bom para **encontrar municípios com déficit**. A sensibilidade menor indica que alguns municípios com perfil desfavorável superaram a expectativa e têm boa cobertura, e esses casos podem servir de exemplo de boas práticas.

Perfil	Urbana (%)	Alfab. (%)	Dens. (hab/km²)	PIBpc (R$)	P(adequado)	Classe
Perfil 1: rural, baixa alfabetização e renda	45	78	12	12.001	3,6%	0 - Inadequado
Perfil 2: intermediário	70	90	40	24.998	38,3%	0 - Inadequado
Perfil 3: urbano, denso, alfabetizado e de renda alta	92	96	500	50.003	86,7%	1 - Adequado

(c) Classificação. O perfil rural, de baixa alfabetização e baixa renda tem probabilidade de cerca de 4% de esgoto adequado (classe 0). O perfil intermediário fica em cerca de 38% (ainda classe 0). O perfil urbano, denso e alfabetizado chega a cerca de 87% (classe 1). Na prática, isso mostra que um município típico brasileiro, de porte e urbanização médios, ainda tende a não ter esgoto adequado.

10. Conclusões e recomendações

- **O déficit de esgoto é o principal gargalo do saneamento municipal** e é muito desigual entre as regiões. Atingir a meta de 90% até 2033 exige um esforço concentrado no Norte, no Nordeste e nos municípios pequenos de todas as regiões.
- **Urbanização e densidade** são os fatores com maior associação com o acesso à rede, o que reflete a economia de escala das redes. Para o campo e as comunidades dispersas, a recomendação é investir em **soluções descentralizadas** (fossas sépticas adequadas, biodigestores, sistemas condominiais), em vez de tentar replicar a rede convencional.
- **A educação** aparece associada ao saneamento mesmo controlando pela urbanização. Isso é coerente com a ideia de que populações mais escolarizadas cobram mais e se mobilizam por infraestrutura, mas não prova causalidade.
- **PIB alto não garante saneamento:** municípios ricos em produção (agro, mineração, energia) devem ser alvo de mecanismos que convertam receita em infraestrutura, como contrapartidas e uso de royalties.
- **Ferramenta CitizenTech:** o modelo logístico, com apenas quatro indicadores públicos do IBGE, pode alimentar um painel de triagem que aponte municípios com alto risco de esgoto inadequado para fiscalização, financiamento ou apoio técnico.

11. Limitações

- Estudo **observacional e transversal**: as associações não provam relações de causa e efeito.
- O PIB é de 2021 e a população é de 2022 (o último PIB municipal com VAB por atividade disponível no SIDRA na coleta), uma pequena defasagem temporal no PIB per capita.
- A normalidade assumida nos itens de probabilidade e testes de hipóteses é uma **aproximação**: a alfabetização é assimétrica e bimodal.
- Os testes de hipóteses usam amostras pequenas sorteadas com semente fixa. Outras amostras podem levar a decisões diferentes, como discutido sobre o erro tipo I.
- As regressões lineares têm heterocedasticidade e resíduos não normais (a resposta é limitada entre 0% e 100%). Os coeficientes descrevem bem as tendências médias, mas os intervalos de confiança devem ser lidos com cautela. Modelos beta ou com erros robustos seriam extensões naturais.
- O limiar de 50% para 'esgoto adequado' é uma escolha analítica. A variável do Censo mede ligação à rede, não o **tratamento** do esgoto.
- A unidade de análise é o município: as conclusões não valem automaticamente para domicílios ou pessoas (falácia ecológica).

12. Referências

- IBGE. Censo Demográfico 2022 — tabelas 4714, 6803, 6805, 6892, 9543 e 9923. SIDRA. https://sidra.ibge.gov.br
- IBGE. Produto Interno Bruto dos Municípios 2021 — tabela 5938. SIDRA. https://sidra.ibge.gov.br
- BRASIL. Lei nº 11.445/2007 e Lei nº 14.026/2020 (Novo Marco Legal do Saneamento Básico).
- Repositório do trabalho: códigos, base de dados e notebook com saídas — ver README.md.